Projet - Big Data / IA / Web

Partie Intelligence Artificielle

FISA4 Brest / Nantes – 2026

Contexte du projet

Déroulement du projet

Données brutes :
Patrimoine_Arbore.csv

Big Data

Analyse et traitement de données

Données traitées :
export_IA.csv

Intelligence artificielle

Prédictions

Scripts python

Développement Web

Interface utilisateur

Application Web

Sujet

Objectif

Concevoir et développer une application de gestion du patrimoine arboré : preuve de concept pour la ville de Saint-Quentin (Aisne)

Approfondir les compétences acquises dans les modules ***Big Data***, ***Intelligence Artificielle***, ***Développement Web*** *et* ***Base de Données*** à travers une application complète de traitements et de visualisation de données.

Objectifs de la partie Intelligence Artificielle :

- Comprendre les étapes d'un projet d'apprentissage automatique
- Apprendre à évaluer une méthode d'apprentissage automatique
- Manipuler les différentes techniques d'apprentissage automatique :
  - Apprentissage non supervisé : clustering
  - Apprentissage supervisé : classification, régression

Mise en situation

Besoin client

1. **Visualisation sur carte :**
   - Créer un visuel sur une carte qui sépare les arbres selon leur taille.
   - L'utilisateur pourra choisir le nombre de catégories (par exemple, deux catégories : petits et grands, ou trois catégories : petits, moyens et grands).

2. **Modèle de prédiction de l'âge :**
   - Développer un modèle d'intelligence artificielle capable de prédire l'âge des arbres.

3. **Système d'alerte pour les tempêtes :**
   - Mettre en place un système d'alerte pour prédire la position des arbres susceptibles d'être déracinés en cas de tempête.

Cahier des charges

Cahier des charges

Fonctionnalités

5 fonctionnalités principales sont attendues :

1. Préparation des données **(pour les besoins client 1, 2 et 3)**
2. Apprentissage non-supervisé **(pour les besoins client 1)**
3. Apprentissage supervisé **(pour les besoins client 2 et 3)**
4. Métriques **(pour les besoins client 1, 2 et 3)**
5. Création de scripts utilisables en ligne de commande **(pour les besoins client 1, 2 et 3)**

Attention

Les fonctionnalités additionnelles que vous développerez seront évaluées uniquement si les fonctionnalités principales sont en place.

Environnement de travail

Environnement de travail

Préparation de l'environnement de travail et gestion de projet :

- Outil de développement : *VSCode*
- Installation des packages : *pandas*, *sklearn*, *plotly*…
- *Gantt*
- *Git* (si possible)

→ **Attendus : diagramme de *Gantt* (et dépôt *Git* si possible)**

Réalisation du Besoin client 1 : Visualisation sur carte

Besoin client 1 : Visualisation sur carte

Visualisation sur carte :

- Créer un visuel sur une carte qui sépare les arbres selon leur taille.
- L'utilisateur pourra choisir le nombre de catégories (par exemple, deux catégories : petits et grands, ou trois catégories : petits, moyens et grands).

Les étapes à suivre pour réaliser le besoin client 1 :

1. Préparation des données
2. Apprentissage non supervisé
3. Métrique pour apprentissage non supervisé
4. Visualisation sur carte
5. Préparation d'un script *Python*

Besoin client 1 : Visualisation sur carte

- **Préparation des données :**
  - Extraction des données d'intérêt : sélectionner les colonnes pertinentes de la base de données selon ce besoin.
  - Encodage des données catégorielles si nécessaire : utiliser des techniques de prétraitement pour convertir les données non numériques en données numériques si nécessaire. Référez-vous à https://scikit-learn.org/stable/modules/preprocessing.html
- **Apprentissage non-supervisé :**
  - Choix de l'algorithme de clustering : sélectionner **un/des algorithme(s)** de clustering pour séparer les arbres en groupes basés sur leur taille. Référez-vous à https://scikit-learn.org/stable/modules/clustering.html
  - Détermination du nombre de clusters : expérimenter avec différents nombres de clusters pour voir quel modèle offre la meilleure séparation des tailles d'arbres.
- **Métriques pour l'apprentissage non-supervisé :**
  - Évaluation des clusters : utiliser des métriques pour évaluer la qualité du clustering. Référez-vous aux méthodes : *Silhouette Coefficient , Calinski-Harabasz Index , Davies-Bouldin Index*.
- **Visualisation sur un carte :**
  - Création de la carte : utiliser une bibliothèque de visualisation pour représenter les arbres sur une carte avec des couleurs différentes pour chaque cluster. Référez-vous à https://plotly.com/python/scattermapbox/
- **Préparation d'un script :**
  - Écrire un script prenant en entré les spécificités d'un arbre et qui renvoie le cluster associé. Un exemple de script est fourni dans les ressources du projet.

    Attention : le script ne doit pas relancer une recherche des clusters à chaque usage, il doit impérativement charger le modèle préalablement enregistré.

→ **Attendus : le notebook commenté, le script final, la partie du rapport traitant le besoin client 1**

Besoin client 1 : Visualisation sur carte

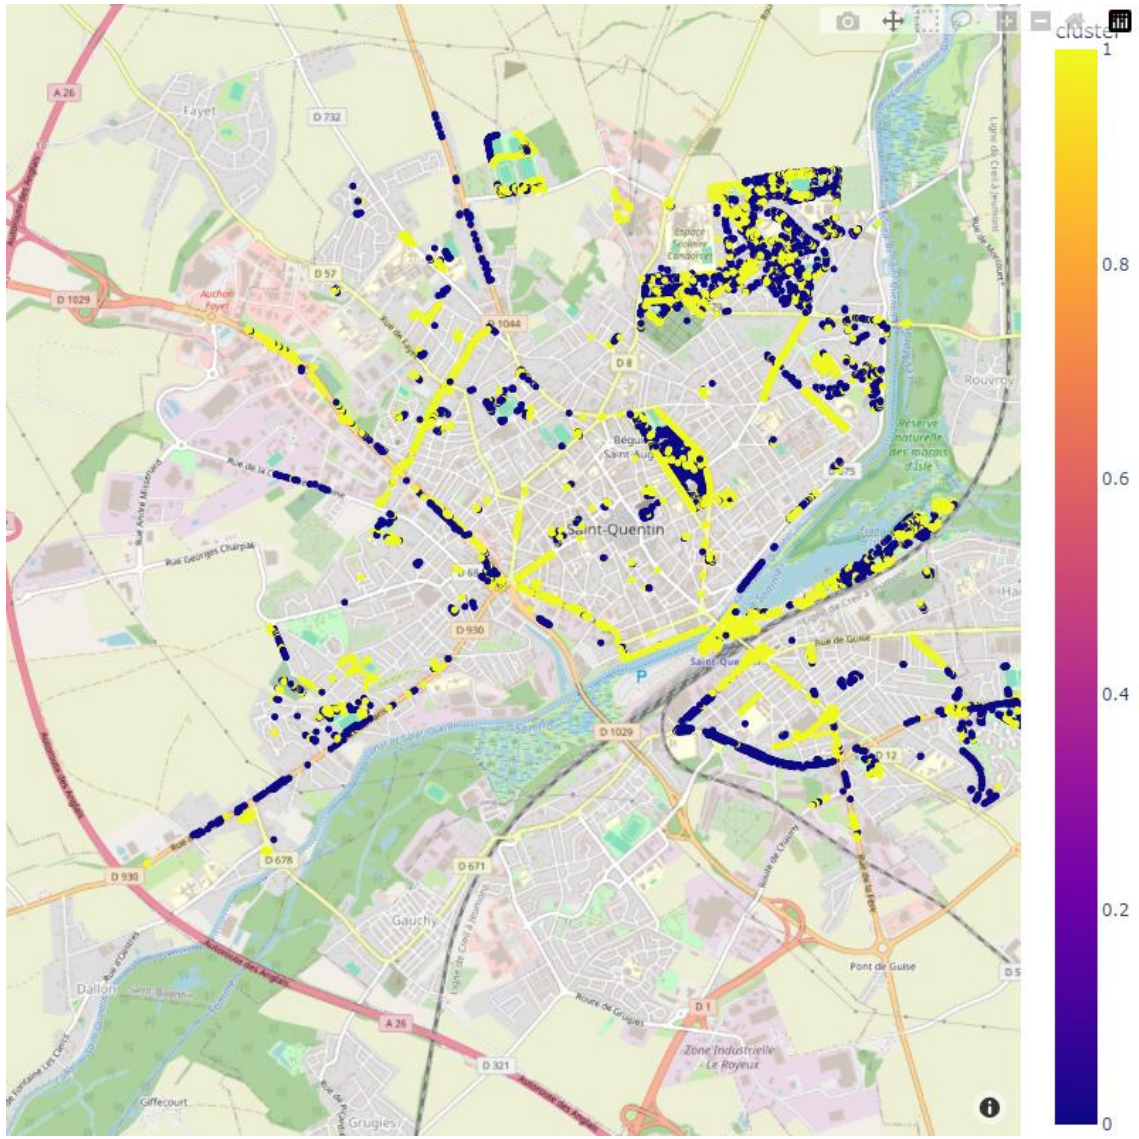

Réalisation du Besoin client 2 : Modèle de prédiction de l'âge

Besoin client 2 : Modèle de prédiction de l'âge

Modèle de prédiction de l'âge :

- Développer un modèle d'intelligence artificielle capable de prédire l'âge des arbres.

Les étapes à suivre pour réaliser le besoin client 2 :

1. Préparation des données
2. Apprentissage supervisé pour la classification
3. Métrique pour la classification
4. Préparation d'un script *Python*

Besoin client 2 : Modèle de prédiction de l'âge

- **Préparation des données :**
  - Extraction des données d'intérêt : Sélectionner les colonnes pertinentes de la base de données selon ce besoin.
  - Encodage des données catégorielles.
  - Normalisation des données ou pas.
  - Cible : `('age_estim')`
  - Utiliser des techniques de prétraitement de données pour préparer les données d'apprentissage. Référez-vous à https://scikit-learn.org/stable/modules/preprocessing.html

  Attention : Enregistrer vos modèles de prétraitement de données, c'est important pour le script final et le projet WEB.
- **Apprentissage supervisé pour la classification :**
  - Choix de l'algorithme d'apprentissage : Sélectionner **des/un algorithme(s)** d'apprentissage pour prédire l'âge. Référez-vous à https://scikit-learn.org/stable/supervised_learning.html#
- **Métriques pour la classification :**
  - Évaluation de résultats de la classification : Utiliser des métriques pour évaluer la qualité du modèle de la classification. Référez-vous à https://scikit-learn.org/stable/modules/model_evaluation.html.
  - Utilisation du GridSearchCV pour tester toutes les combinaisons possibles avec **plusieurs hyperparamètres du modèle** et trouver le meilleur modèle de prédiction. Référez-vous à https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- **Préparation d'un script :**
  - Écrire un script prenant en entrée les spécificités d'un arbre et qui renvoie la prédiction de son âge. Un exemple de script est fourni dans les ressources du projet.

  Attention : le script ne doit pas relancer un apprentissage à chaque usage, il doit impérativement charger les modèles préalablement enregistrés.

→ **Attendus : le notebook commenté, le script final, la partie du rapport traitant le besoin client 2**

Réalisation du Besoin client 3 : Système d'alerte pour les tempêtes

Besoin client 3 : Système d'alerte pour les tempêtes

Système d'alerte pour les tempêtes :

- Mettre en place un système d'alerte pour prédire les arbres susceptibles d'être déracinés en cas de tempête.

Les étapes à suivre pour réaliser le besoin client 3 :

1. Préparation des données
2. Apprentissage supervisé pour la classification
3. Métrique pour la classification
4. Préparation d'un script *Python*

Besoin client 3 : Système d'alerte pour les tempêtes

- **Préparation des données :**
  - Extraction des données d'intérêt : Sélectionner les colonnes pertinentes de la base de données selon ce besoin.
  - Encodage des données catégorielles.
  - Normalisation des données ou pas.
  - Cible : `('fk_arb_etat')`
  - Utiliser des techniques de prétraitement de données pour préparer les données d'apprentissage. Référez-vous à https://scikit-learn.org/stable/modules/preprocessing.html

  Attention : Enregistrer vos modèles de prétraitement de données, c'est important pour le script final et le projet WEB.
- **Apprentissage supervisé pour la classification :**
  - Choix de l'algorithme d'apprentissage : Sélectionner **des/un algorithme(s)** d'apprentissage pour prédire l'alerte. Référez-vous à https://scikit-learn.org/stable/supervised_learning.html#
- **Métriques pour la classification :**
  - Évaluation de résultats de la classification : Utiliser des métriques pour évaluer la qualité du modèle de classification. Référez-vous à https://scikit-learn.org/stable/modules/model_evaluation.html.
  - Utilisation du GridSearchCV pour tester toutes les combinaisons possibles avec **plusieurs hyperparamètres du modèle** et trouver le meilleur modèle de prédiction à https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- **Préparation d'un script :**
  - Écrire un script prenant en entrée les spécificités d'un arbre et qui renvoie la prédiction de son déracinement lors d'une tempête. Un exemple de script est fourni dans les ressources du projet.

    Attention : le script ne doit pas relancer un apprentissage à chaque usage, il doit impérativement charger les modèles préalablement enregistrés.

→ **Attendus : le notebook commenté, le script final, la partie du rapport traitant le besoin client 3**

Déroulement

Déroulement

Organisation

Travail en trinôme :

- Chaque étudiant dans le trinôme connaît l'ensemble du projet : **utiliser le gestionnaire de code *Git* si possible**
- Attention à bien se répartir le travail en prévoyant les tâches de chacun avec un **diagramme de *Gantt***

Point d'avancement :

- Des points d'avancement sont prévus avec votre client (qui est votre enseignant)

Ressources externes :

- Tous les documents sont autorisés
- Attention à utiliser avec une grande précaution tout document extérieur : site de vulgarisation, forum, code d'autrui

Documentation du projet :

- Au fur et à mesure
- Standardisée
- Livraison de code ou de documents :
  - Ne pas attendre la dernière minute pour poster un livrable
  - Préparer des livrables intermédiaires (surtout pour les sources)
  - Sauvegarder régulièrement vos scripts et résultats

Livrables et évaluations

Livrable

Format de l'archive :

Archive *ZIP*, *TGZ*, *7ZIP*, pas de *RAR :* `projetia_groupeX.zip` (remplacer X par votre numéro de trinôme)

Le rendu final doit contenir :

- Trois dossiers : *Besoin_Client_1*, *Besoin_Client_2* et *Besoin_Client_3*
- Dans chaque dossier on doit trouver :
  - La base de données utilisée (*.csv*)
  - Le Notebook de la partie expérimentale (*.ipynb*) commenté et exécutable sans erreur
  - Le script final (*.py*)
  - Les ressources nécessaires (comme les modèles enregistrés (*.pkl*))
  - Le Readme.txt pour décrire comment utiliser le script final avec un script d'exemple
- Un rapport (*.pdf*) de 11 pages (dont 1 page de diagramme de *Gantt*) dans lequel sont formalisés les différents attendus

Remarques :

- Malus possible sur l'un des membres du groupe si l'investissement est jugé trop faible
- Possibilité d'être interrogé durant le projet de façon individuelle
- Plagiat sévèrement sanctionné pour TOUS les membres du / des groupe(s)

Attention

Les livrables seront à poster sur l'intranet. Tout retard sera sanctionné (l'heure du réseau faisant foi).
Les fichiers au mauvais format ou avec un mauvais nommage seront pénalisés.

Évaluation

Présentation orale

- Soutenance de 10 minutes (strict) + 5 minutes de questions
- Présentation en trinôme (pensez à vous répartir la parole)
- Présentez l'essentiel de votre projet

Code et rapport :

- Rendu de l'intégralité de vos codes sources
- Rapport du trinôme présentant les attendus du projet
- **Aucun code ne doit apparaître dans le rapport et la présentation**

Evaluations des compétences :

- Des questions seront posées tout au long du projet pour vérifier les acquis

Barème indicatif : Soutenance 40% – Compétences 40% – Évaluation du rapport + code 20%

ISEN
ALL IS DIGITAL!

yncréa

MERCI

Des questions ?